Contacto:

- Franco Vanotti - fvanotti15@gmail.com
- Felipe Miriuka - fmmiriuka@gmail.com
- Santiago Zegers - zegerssantiagob@gmail.com

Evaluación de modelos preentrenados para etiquetado automático de música

Descripción de la tarea

El sistema recibe como entrada un fragmento de audio musical de duración fija (en este caso, clips de 29 segundos de MagnaTagATune) que los modelos convierten internamente en un espectrograma mel. A la salida se obtiene un vector de puntuaciones continuas en [0,1], una por etiqueta, interpretable como la probabilidad estimada de que esa etiqueta aplique al fragmento.

Trabajamos con alrededor de 50 etiquetas (géneros, instrumentos, presencia de voz, tempo, etc) y, como una misma canción puede tener varias al mismo tiempo (por ejemplo, rock, guitar y male vocal juntas), se trata de un problema de clasificación multi-label y no de clasificación multiclase tradicional.

Los modelos que vamos a usar (MTT_musicnn y MTT_vgg) ya están entrenados, así que no vamos a tocar la loss durante este TP, pero vale la pena tenerla presente porque ayuda a interpretar sus salidas. En ambos casos se entrenaron con binary cross-entropy calculada etiqueta por etiqueta (una sigmoide independiente por etiqueta) y promediada sobre el conjunto completo de etiquetas.

Para evaluar este tipo de sistemas se suelen usar métricas de clasificación multi-label como AUC-ROC y AUC-PR, tanto promediadas como por etiqueta individual, además de Precision, Recall y F1-score una vez fijado un umbral de decisión sobre las puntuaciones.

Descripción de los datos

Vamos a trabajar con MagnaTagATune (MTT), un dataset de 25.863 clips de 29 segundos sacados de 5.405 canciones (alrededor de 230 artistas y 446 álbumes) del sitio magnatune.com. Las etiquetas se recolectaron de forma colaborativa mediante un juego TagATune, y el vocabulario completo tiene 188 etiquetas libres entre géneros, instrumentos, voz, estado de ánimo, etc. Como MTT_musicnn y MTT_vgg fueron entrenados y evaluados originalmente sobre el subconjunto de las 50 etiquetas más frecuentes, vamos a usar ese mismo subconjunto para poder comparar contra los resultados reportados en el trabajo original.

No vamos a usar cross-validation. El dataset se distribuye en 16 carpetas identificadas con un dígito hexadecimal (0-9, a-f), y el split que se volvió estándar en la literatura (y que también usa musicnn) asigna las carpetas 0-9, a y b al entrenamiento (más o menos 19.000 clips), la carpeta c a validación (más o menos 1.600 clips) y las carpetas d, e y f a evaluación (más o menos 6.100 clips). Cómo no vamos a reentrenar nada, sólo necesitamos descargar validación y evaluación (unos 7.700 clips en total). La validación la vamos a usar para tomar decisiones que no implican tocar los pesos de la red (elegir un umbral, ajustar una calibración, definir una función de costo entre etiquetas), y dejamos la evaluación aparte para reportar las métricas finales sin haber “espiado” antes ese conjunto. Todavía nos falta confirmar los tamaños exactos una vez que descarguemos los datos.

La metadata disponible incluye, para cada clip, el vector de etiquetas binario y el identificador de la canción, el artista y el álbum de origen. Esto último sirve para chequear que los clips de una misma canción no terminen repartidos entre distintos conjuntos. Ahí aparece la principal correlación que sospechamos, siendo que cada canción se parte en varios clips (en promedio, unos 4 o 5), que comparten timbre e instrumentación entre sí, con lo cual hay riesgo real de data leakage si el split no los mantiene agrupados. A esto se suma un agrupamiento más sutil por artista y álbum, (un mismo artista tiende a repetir estilo y etiquetas de uan cancion a otra) y un desbalance bastante marcado en la frecuencia de las etiquetas, con algunas mucho más comunes que otras, algo que probablemente termine afectando las métricas agregadas.

Modelos

Vamos a trabajar con dos modelos preentrenados de la biblioteca musiccnn, MTT_musicnn, cuyas primeras capas usan filtros convolucionales diseñados a propósito para capturar patrones musicales (unos enfocados en timbre, y otros en estructura temporal a distintas escalas), seguidas de unas capas densas que combinan esa información y producen la predicción final; y MTT_vgg, una CNN, con filtros chicos apilados y genéricos (no diseñados pensando en audio) sobre el espectrograma. Los dos fueron entrenados sobre MagnaTagATune con las 50 etiquetas más frecuentes y no los vamos a reentrenar. La idea es usarlos únicamente para inferencia, como caso de estudio para pensar en problemas de evaluación.

Análisis planeado (propuesta preliminar, sujeta a comentarios)

- Comparar los dos modelos con varias métricas (AUC-ROC, AUC-PR, Precision/Recall/F1) y ver si cambia el modelo "ganador" según qué métrica se mira, o según se evalúe de forma agregada o etiqueta por etiqueta.
- Ver cómo cambia el trade-off entre Precision y Recall a medida que se mueve el umbral de decisión sobre las puntuaciones.
- Pensar si tiene sentido penalizar distintos ciertos errores (por ejemplo, confundir dos géneros parecidos no debería costar lo mismo que confundir dos géneros muy distintos) y probar una función de costo no uniforme.
- Mirar qué tan bien calibradas están las puntuaciones de cada modelo. Si una puntuación de 0.9 realmente corresponde una probabilidad alta de que la etiqueta esté presente.
- Desagregar los resultados por etiqueta (frecuentes vs raras) para ver si las métricas globales estarán tapando diferencias importantes.
- Evaluar qué tan robustos son los modelos frente a cambios en el audio de entrada (bajar la calidad, recortar la duración de los clips, agregar ruido) comparando contra las condiciones originales del propio conjunto de evaluación de MTT, para estudiar problemas de domain mismatch sin necesidad de otro dataset. (Como posible extensión se podría comparar contra una dataset distinto con etiquetas mapeables)
- Si da tiempo, acompañar las conclusiones con intervalos de confianza o bootstrap para ver qué tan estables son.

Referencias

- musicnn — modelos preentrenados MTT_musicnn y MTT_vgg (Pons & Serra, 2019)
- The MagnaTagATune Dataset — City University MIRG (página oficial del dataset)
- MagnaTagATune Dataset — resumen y estadísticas (Papers with Code)
- Law, E., West, K., Mandel, M., Bay, M., & Downie, J. S. (2009). Evaluation of Algorithms Using Games: The Case of Music Tagging. ISMIR.